

Aplikacja edukacyjna: Algorytmy Genetyczne

Piotr Kluczyński, Michał Małecki

1. Przeznaczenie aplikacji

Celem projektu jest stworzenie aplikacji edukacyjnej wspomagającej naukę oraz pogłębianie zrozumienia działania algorytmów genetycznych. Aplikacja skierowana jest przede wszystkim do użytkowników posiadających podstawową wiedzę z zakresu sztucznej inteligencji, metod optymalizacji oraz terminologii związanej z algorytmami ewolucyjnymi.

Projekt ma za zadanie w przystępny i interaktywny sposób przedstawić mechanizmy działania algorytmów genetycznych, ich właściwości, ograniczenia oraz różnorodne możliwości zastosowań. Szczególny nacisk położono na aspekt edukacyjny - użytkownik może nie tylko uruchamiać algorytm, ale również obserwować przebieg jego działania krok po kroku, analizować kolejne etapy ewolucji populacji oraz interpretować wpływ poszczególnych parametrów na końcowy wynik.

Dzięki możliwości śledzenia przebiegu obliczeń użytkownik zdobywa praktyczną wiedzę oraz intuicję dotyczącą sposobu rozwiązywania problemów optymalizacyjnych z wykorzystaniem metod inspirowanych procesami ewolucji biologicznej. Aplikacja pozwala również na eksperymentowanie z różnymi konfiguracjami parametrów algorytmu, co umożliwia obserwację wpływu zmian na szybkość zbieżności, jakość rozwiązania oraz stabilność działania algorytmu.

Projekt może pełnić funkcję narzędzia dydaktycznego wykorzystywanego podczas zajęć z zakresu sztucznej inteligencji, optymalizacji lub algorytmiki, a także stanowić pomoc edukacyjną dla osób samodzielnie zgłębiających temat algorytmów ewolucyjnych.

2. Funkcjonalności

2.1 Hybrydowy interfejs użytkownika

Ze względu na zakres oraz charakter projektu zdecydowano się na zastosowanie hybrydowego interfejsu użytkownika, łączącego tekstowy interfejs konsolowy z prostą warstwą graficzną odpowiedzialną za wizualizację danych. Takie rozwiązanie pozwala na zachowanie przejrzystości aplikacji oraz wygodną prezentację wyników działania algorytmu.

Główna część interakcji użytkownika z aplikacją odbywa się za pośrednictwem konsoli systemowej. Użytkownik porusza się po dostępnych opcjach programu poprzez wybór liczb przypisanych do konkretnych funkcji aplikacji. Interfejs konsolowy odpowiada za obsługę menu, konfigurację działania programu oraz prezentację informacji tekstowych.

<Screenshot menu w konsoli>

W konsoli wyświetlane są również zbiorcze informacje dotyczące działania algorytmu, takie jak statystyki przebiegu obliczeń, informacje o najlepszym znalezionym rozwiązaniu czy podsumowanie działania programu. Dzięki temu użytkownik ma dostęp do najważniejszych danych w uporządkowanej i łatwej do odczytania formie.

<Screenshot po zakończeniu działania algorytmu genetycznego>

Ze względu na ograniczoną czytelność prezentowania większej ilości danych statystycznych bezpośrednio w konsoli, część odpowiedzialna za wizualizację statystyk populacji została zaimplementowana w osobnym oknie aplikacji. Pozwala to na bardziej przejrzyste przedstawienie zmian zachodzących podczas działania algorytmu oraz ułatwia analizę wyników.

<Screenshot wykresu w oddzielnym oknie>

Zastosowanie dwóch sposobów prezentacji danych - tekstowego oraz graficznego - umożliwia jednocześnie zachowanie prostoty obsługi aplikacji i czytelnej wizualizacji procesu działania algorytmu genetycznego.

2.2 Zaprezentowanie klasycznych problemów

Ze względu na edukacyjny charakter aplikacji, projekt skupia się na przedstawieniu klasycznych problemów rozwiązywanych przy pomocy algorytmów genetycznych. Celem tego rozwiązania jest umożliwienie użytkownikowi poznania sposobu działania algorytmów genetycznych w różnych typach przestrzeni problemowych oraz zrozumienie wpływu reprezentacji chromosomu na przebieg procesu ewolucji.

W aplikacji algorytm genetyczny może działać w jednym z trzech trybów pracy. Wybór konkretnego trybu wpływa między innymi na:

- sposób reprezentacji chromosomów,
- dostępne operatory genetyczne,
- metodę interpretacji osobników,

- charakter rozwiązywanego problemu.

Optymalizacja funkcji liczb całkowitych

Jest to jedna z najczęściej wykorzystywanych kategorii problemów podczas prezentowania podstaw działania algorytmów genetycznych. W tym przypadku rozwiązanie kodowane jest w postaci chromosomu o stałej długości, najczęściej zapisanego w systemie binarnym lub innym systemie liczbowym.

Każdy osobnik reprezentuje konkretny zestaw parametrów funkcji optymalizacyjnej, natomiast proces ewolucji prowadzi do znalezienia rozwiązania maksymalizującego lub minimalizującego wartość funkcji celu.

Ten rodzaj problemów pozwala w prosty sposób zaprezentować podstawowe mechanizmy działania algorytmów genetycznych, takie jak:

- kodowanie genotypu,
- selekcja osobników,
- operacje krzyżowania,
- mutacje bitowe,
- ocenę funkcji przystosowania.

<Screenshot przedstawiający przykładową funkcję/chromosom>

Optymalizacja funkcji liczb zmiennoprzecinkowych

Problemy wykorzystujące parametry zmiennoprzecinkowe wymagają zastosowania odmiennego sposobu reprezentacji chromosomu niż w przypadku liczb całkowitych. W aplikacji uwzględniono dwa najczęściej stosowane podejścia do kodowania tego typu problemów.

Pierwszym rozwiązaniem jest wykorzystanie reprezentacji binarnej, w której wartości zmiennoprzecinkowe kodowane są jako ciągi bitów z określoną wcześniej precyzją. Drugim podejściem jest bezpośrednia reprezentacja zmiennoprzecinkowa, w której każdy gen przechowuje wartość liczbową typu zmiennoprzecinkowego.

Zastosowanie obu metod pozwala użytkownikowi zaobserwować różnice pomiędzy sposobami reprezentacji danych oraz ich wpływem na działanie algorytmu genetycznego.

<Screenshot przedstawiający przykładową funkcję/chromosom>

Problemy porządkowania

Trzecia kategoria obejmuje problemy, w których rozwiązaniem jest znalezienie poprawnej kolejności elementów w chromosomie. Do najbardziej znanych przykładów tego typu zadań należy problem komiwojażera.

W przeciwieństwie do klasycznych problemów optymalizacyjnych, w problemach porządkowania istotne jest zachowanie poprawności permutacji elementów. Oznacza to konieczność zastosowania specjalnych operatorów genetycznych, które nie powodują powstawania niepoprawnych rozwiązań zawierających powtórzenia lub brakujące elementy.

Implementacja tego typu problemów pozwala na przedstawienie bardziej zaawansowanych aspektów algorytmów genetycznych oraz pokazuje, że sposób reprezentacji chromosomu ma bezpośredni wpływ na dobór metod krzyżowania i mutacji.

<Screenshot przedstawiający przykładową funkcję/chromosom>

Aplikacja umożliwia konfigurację wielu parametrów związanych z każdym z opisanych trybów pracy. Dzięki temu użytkownik może eksperymentować z różnymi metodami reprezentacji danych oraz obserwować wpływ poszczególnych ustawień na skuteczność działania algorytmu genetycznego w różnych klasach problemów.

2.3 Dowolność w definiowaniu osobników

Aplikacja umożliwia użytkownikowi definiowanie struktury osobników wykorzystywanych przez algorytm genetyczny. Konfiguracja nie ogranicza się jedynie do wyboru sposobu reprezentacji genów, ale pozwala również na tworzenie bardziej złożonych organizmów diploidalnych, inspirowanych mechanizmami występującymi w biologii.

W standardowym modelu każdy osobnik posiada pojedynczy chromosom zawierający zestaw genów reprezentujących rozwiązanie problemu. W aplikacji zaimplementowano również możliwość wykorzystania osobników diploidalnych, w których każdy gen występuje w dwóch wariantach:

- dominującym,
- recesywnym.

Rozwiązanie to zostało zrealizowane poprzez zastosowanie dodatkowego chromosomu kontrolnego, zbudowanego z wartości binarnych. Chromosom ten określa, który z dwóch wariantów genu jest aktualnie dominujący i wpływa na fenotyp osobnika.

Interpretacja wartości przebiega następująco:

- wartość 0 oznacza dominację genu znajdującego się w pierwszym chromosomie,
- wartość 1 oznacza dominację genu znajdującego się w drugim chromosomie.

Dzięki temu każdy gen osobnika posiada dwa potencjalne warianty, z których tylko jeden bierze bezpośredni udział w ocenie funkcji przystosowania.

<Screenshot przedstawiający przykładowego osobnika diploidalnego>

Dodatkowe chromosomy podlegają tym samym operacjom genetycznym co standardowe chromosomy. Oznacza to, że podczas działania algorytmu uczestniczą w procesach:

- krzyżowania,
- mutacji,
- dziedziczenia cech przez kolejne pokolenia.

Pozwala to zachować spójność działania całego modelu ewolucyjnego niezależnie od poziomu złożoności reprezentacji osobnika.

Wprowadzenie organizmów diploidalnych umożliwia zaprezentowanie bardziej zaawansowanych zastosowań algorytmów genetycznych, szczególnie w kontekście środowisk dynamicznych oraz funkcji przystosowania zmieniających się w czasie. Dzięki przechowywaniu alternatywnych wariantów genów algorytm może zachować część wcześniej wypracowanych cech populacji i ponownie je wykorzystać po zmianie warunków optymalizacji. Mechanizm ten pozwala ograniczyć utratę różnorodności populacji oraz poprawić zdolność adaptacji algorytmu do zmieniających się problemów.

2.4 Szeroka gama operatorów genetycznych

Jednym z głównych założeń projektu było umożliwienie użytkownikowi zapoznania się z różnorodnością technik wykorzystywanych w algorytmach genetycznych. W związku z tym aplikacja została wyposażona w szeroki zestaw operatorów genetycznych, obejmujących zarówno klasyczne rozwiązania, jak i bardziej zaawansowane warianty stosowane w zależności od rodzaju problemu oraz reprezentacji chromosomu.

Zastosowane operatory wpływają bezpośrednio na przebieg procesu ewolucji populacji, sposób eksploracji przestrzeni rozwiązań oraz zdolność algorytmu do odnajdywania optymalnych wyników. Możliwość swobodnego wyboru operatorów pozwala użytkownikowi przeprowadzać eksperymenty oraz analizować wpływ konkretnych technik na skuteczność działania algorytmu.

Operatory selekcji

Aplikacja umożliwia wykorzystanie wielu metod selekcji osobników uczestniczących w procesie reprodukcji. Zaimplementowane zostały następujące warianty:

- próbka deterministyczna (Deterministic Sampling),
- próbka statystyczna (Stochastic Sampling) z lub bez powtórzeń,

- deterministyczne próbkowanie z resztą (Remainder Stochastic Sampling) z lub bez powtórzeń,
- turniej stochastyczny (Stochastic Tournament),
- selekcja oparta na randze (Rank Selection) w wariancie liniowym lub wykładniczym.

Różne strategie selekcji pozwalają kontrolować poziom presji selekcyjnej oraz wpływają na tempo zbieżności algorytmu i zachowanie różnorodności populacji.

Operatory krzyżowania

W aplikacji zaimplementowano wiele metod krzyżowania dostosowanych do różnych sposobów reprezentacji chromosomów:

- krzyżowanie jednopunktowe (Single Point Crossover),
- krzyżowanie wielopunktowe (k-Point Crossover),
- krzyżowanie równomierne (Uniform Crossover),
- rekombinację dyskretną (Discrete Recombination),
- rekombinację pośrednią (Intermediate Recombination),
- częściowe dopasowanie (PMX – Partially Matched Crossover),
- krzyżowanie porządkowe (Order Crossover),
- krzyżowanie cykliczne (Cycle Crossover).

Dzięki obecności wielu wariantów możliwe jest przedstawienie różnic pomiędzy operatorami przeznaczonymi dla klasycznych chromosomów binarnych, reprezentacji zmiennoprzecinkowych oraz problemów permutacyjnych.

Operatory mutacji

Proces mutacji został rozszerzony o kilka różnych metod modyfikacji genów:

- mutację jednopunktową (Single Point Mutation),
- mutację Gaussa (Gaussian Mutation),
- rotację chromosomu (Rotation) w lewo lub w prawo,
- inwersję (Inversion).

Zastosowanie różnych operatorów mutacji umożliwia obserwację wpływu losowych zmian na różnorodność populacji oraz zdolność algorytmu do unikania lokalnych ekstremów funkcji celu.

Dodatkowe mechanizmy ewolucyjne

Oprócz podstawowych operatorów genetycznych aplikacja obsługuje również dodatkowe mechanizmy wpływające na przebieg ewolucji:

- elitaryzm (Elitism),
- przepaść pokoleniową (Generational Gap).

Mechanizmy te pozwalają kontrolować sposób przechodzenia osobników pomiędzy kolejnymi pokoleniami oraz wpływają na stabilność procesu optymalizacji.

Nie wszystkie operatory mogą zostać wykorzystane dla każdego typu chromosomu. Część metod została zaprojektowana wyłącznie dla określonych reprezentacji danych, takich jak chromosomy binarne, zmiennoprzecinkowe lub permutacyjne. Aplikacja uwzględnia te ograniczenia i pozwala jedynie na wybór kompatybilnych kombinacji operatorów.

Dzięki dużej liczbie dostępnych technik użytkownik może przeprowadzać rozbudowane eksperymenty oraz analizować wpływ poszczególnych operatorów na działanie algorytmu genetycznego w różnych klasach problemów.

2.5 Dostosowanie funkcji docelowej i funkcji fitnessu

Aplikacja umożliwia użytkownikowi definiowanie własnej funkcji docelowej wykorzystywanej podczas procesu optymalizacji. Funkcja ta może przyjmować postać funkcji jednej lub dwóch zmiennych oraz działać zarówno w trybie minimalizacji, jak i maksymalizacji wartości.

Możliwość definiowania własnych funkcji pozwala na testowanie działania algorytmu genetycznego w różnych warunkach oraz analizowanie jego skuteczności dla problemów o odmiennych charakterystykach przestrzeni rozwiązań.

Dodatkowo aplikacja obsługuje funkcje zmiennie w czasie. Oznacza to, że parametry lub kształt funkcji docelowej mogą ulegać zmianie podczas działania algorytmu. Rozwiązanie to pozwala na symulowanie dynamicznych środowisk optymalizacyjnych oraz obserwację zdolności populacji do adaptacji w zmieniających się warunkach.

Oprócz samej funkcji docelowej użytkownik może również modyfikować sposób obliczania funkcji fitness. Funkcja fitness odpowiada za ocenę jakości osobników i bezpośrednio wpływa na proces selekcji podczas działania algorytmu genetycznego.

W aplikacji zaimplementowano możliwość wykorzystania następujących modyfikacji funkcji fitness:

- skalowanie liniowe lub potęgowe (*Linear/Power Scaling*),

- mechanizm zapobiegania nisdom (*Sharing*),
- obsługę ograniczeń,
- własne modyfikacje wykorzystujące klasyczne funkcje i operacje matematyczne.

Skalowanie funkcji fitness pozwala kontrolować różnice pomiędzy ocenami poszczególnych osobników, co może wpływać na siłę presji selekcyjnej oraz stabilność działania algorytmu.

Mechanizm *Sharing* umożliwia ograniczenie dominacji pojedynczych obszarów przestrzeni rozwiązań poprzez promowanie różnorodności populacji. Dzięki temu algorytm może jednocześnie eksplorować wiele potencjalnych rozwiązań zamiast przedwcześnie zbiegać do jednego optimum lokalnego.

Obsługa ograniczeń pozwala definiować warunki, które muszą zostać spełnione przez rozwiązania problemu. Osobniki niespełniające określonych wymagań mogą zostać odpowiednio ukarane podczas oceny funkcji fitness.

Aplikacja umożliwia również tworzenie własnych modyfikacji funkcji fitness przy pomocy standardowych operacji matematycznych i funkcji analitycznych. Pozwala to użytkownikowi dostosować sposób oceny osobników do specyfiki badanego problemu oraz przeprowadzać bardziej zaawansowane eksperymenty związane z działaniem algorytmów genetycznych.

2.6 Wsparcie w zdefiniowaniu problemu

Aplikacja została zaprojektowana w sposób ułatwiający użytkownikowi konfigurację problemu optymalizacyjnego oraz przygotowanie odpowiedniej reprezentacji chromosomu. Część procesów związanych z definiowaniem parametrów działania algorytmu została zautomatyzowana, aby ograniczyć konieczność ręcznego wykonywania obliczeń technicznych niezwiązanych bezpośrednio z analizą działania algorytmu genetycznego.

Podczas definiowania problemu użytkownik może określić, czy parametry funkcji powinny być reprezentowane jako liczby naturalne czy liczby rzeczywiste. Na podstawie wybranego typu danych aplikacja automatycznie wyznacza odpowiednią długość chromosomu oraz sposób kodowania genów.

<Screenshot przedstawiający opcję wybierania formy chromosomu>

Automatyczne generowanie reprezentacji chromosomu pozwala uprościć proces konfiguracji oraz zmniejsza ryzyko błędnego doboru parametrów kodowania. Dzięki temu użytkownik może skupić się przede wszystkim na analizie działania algorytmu oraz eksperymentowaniu z różnymi konfiguracjami operatorów genetycznych.

Aplikacja umożliwia również definiowanie niestandardowego alfabetu chromosomu. Użytkownik może samodzielnie określić zestaw symboli wykorzystywanych podczas reprezentacji genów, co pozwala na

tworzenie bardziej nietypowych wariantów kodowania oraz eksperymentowanie z alternatywnymi sposobami reprezentacji danych.

<Screenshot przedstawiający opcję definiowania chromosomu>

Możliwość dostosowania alfabetu chromosomu zwiększa elastyczność aplikacji i pozwala lepiej zaprezentować wpływ sposobu reprezentacji rozwiązania na działanie algorytmu genetycznego.

2.7 Własne wybieranie meta parametrów algorytmu

Aplikacja umożliwia użytkownikowi pełną konfigurację podstawowych meta-parametrów algorytmu genetycznego. Parametry te mają bezpośredni wpływ na przebieg procesu ewolucji, szybkość działania algorytmu oraz jakość uzyskiwanych rozwiązań.

Użytkownik może samodzielnie dostosować między innymi:

- wielkość populacji,
- warunek zakończenia działania algorytmu,
- prawdopodobieństwo zastosowania operatorów genetycznych,
- liczbę generacji,
- parametry związane z selekcją, krzyżowaniem i mutacją.

<Screenshot przedstawiający menu modyfikacji meta-parametrów>

Możliwość swobodnej konfiguracji parametrów pozwala na przeprowadzanie eksperymentów dotyczących wpływu poszczególnych ustawień na działanie algorytmu genetycznego. Użytkownik może obserwować zmiany dotyczące:

- szybkości zbieżności algorytmu,
- stabilności procesu optymalizacji,
- jakości znajdowanych rozwiązań,
- poziomu różnorodności populacji.

Funkcjonalność ta pełni istotną rolę edukacyjną, ponieważ pozwala lepiej zrozumieć znaczenie odpowiedniego doboru parametrów w algorytmach ewolucyjnych oraz wpływ poszczególnych ustawień na skuteczność rozwiązywania problemów optymalizacyjnych.

2.8 Analiza wyników algorytmu

Po zakończeniu działania algorytmu genetycznego aplikacja prezentuje użytkownikowi zestawienie wyników obejmujące najważniejsze informacje dotyczące przebiegu procesu optymalizacji. Celem tej sekcji jest umożliwienie analizy skuteczności działania algorytmu oraz oceny jakości uzyskanych rozwiązań.

Wyniki podzielone są na dwie główne grupy: statystyki globalne oraz statystyki zmienne w czasie (w ujęciu kolejnych generacji).

Statystyki globalne

W konsoli wyświetlane są podsumowujące informacje dotyczące całego przebiegu działania algorytmu. Obejmują one między innymi:

- liczbę wykonanych operacji krzyżowania,
- liczbę wykonanych mutacji,
- informacje o najlepszym znalezionym osobniku,
- wartość funkcji fitness najlepszego rozwiązania,
- numer generacji, w której najlepszy osobnik pojawił się po raz pierwszy.

<Screenshot przedstawiający sprawozdanie w konsoli na zakończenie działania algorytmu>

Tego typu zestawienie pozwala szybko ocenić ogólną skuteczność algorytmu oraz jego przebieg w trakcie całego procesu optymalizacji.

Statystyki w ujęciu generacji

Oprócz danych globalnych aplikacja umożliwia analizę zmian zachodzących w populacji na przestrzeni kolejnych generacji. Dane te prezentowane są w formie wykresów w oddzielnych oknach aplikacji.

Analizowane są następujące wielkości:

- wartość najlepszego fitnessu w każdej generacji,
- średnia wartość fitnessu populacji,
- najgorsza wartość fitnessu,
- odchylenie standardowe fitnessu.

<Screenshot przedstawiający wygenerowane wykresy>

Taki sposób prezentacji umożliwia obserwację dynamiki procesu ewolucji, w tym tempa zbieżności algorytmu oraz zmian różnorodności populacji w czasie.

Dodatkowo użytkownik ma możliwość zapisania wygenerowanych danych do pliku w wybranym formacie. Funkcjonalność ta pozwala na późniejszą analizę wyników oraz ich wykorzystanie w celach porównawczych lub sprawozdawczych.

2.9 Śledzenie zmian w populacji w czasie rzeczywistym

Aplikacja umożliwia użytkownikowi obserwację zmian zachodzących w populacji w trakcie działania algorytmu genetycznego w formie wizualizacji dynamicznej. W tym celu zaimplementowano „animowany” wykres przedstawiający rozmieszczenie osobników na tle przestrzeni przeszukiwania (krajobrazu funkcji fitness).

Wykres wyświetlany jest w osobnym oknie aplikacji i aktualizuje się automatycznie wraz z kolejnymi generacjami. Każda iteracja algorytmu odpowiada przejściu do kolejnego stanu populacji, co pozwala na wizualne przedstawienie procesu ewolucji oraz zmian zachodzących w rozmieszczeniu osobników w przestrzeni rozwiązań.

<Screenshot przedstawiający wykres>

Dzięki tej formie prezentacji użytkownik może w intuicyjny sposób zaobserwować:

- proces zbieżności populacji do obszarów o wysokiej wartości fitness,
- zanikanie lub utrzymywanie się różnorodności osobników,
- dynamikę zmian w kolejnych pokoleniach,
- wpływ losowości oraz operatorów genetycznych na rozkład populacji.

Dodatkowo aplikacja udostępnia możliwość sterowania przebiegiem symulacji. Użytkownik może w dowolnym momencie wstrzymać automatyczne przechodzenie między generacjami, a następnie ręcznie przechodzić do kolejnych kroków za pomocą dedykowanego przycisku. Funkcjonalność ta pozwala na dokładniejszą analizę poszczególnych etapów ewolucji oraz lepsze zrozumienie mechanizmów działania algorytmu genetycznego.

2.10 Badanie schematów w populacji

Aplikacja umożliwia użytkownikowi dodatkową interakcję z wizualizacją działania algorytmu genetycznego podczas obserwacji populacji w krajobrazie funkcji fitness. Funkcjonalność ta pozwala na bardziej szczegółową analizę struktury populacji oraz mechanizmów dziedziczenia cech.

W trakcie działania animacji użytkownik może aktywować filtr schematów (schema), który umożliwia identyfikację osobników spełniających określony wzorzec genotypu. Filtr ten pozwala na wizualne wyróżnienie fragmentów populacji, które zawierają dany schemat oraz obserwację jego rozprzestrzeniania się w kolejnych generacjach.

<Screenshot przedstawiający wykres z nałożonym filtrem schematu>

Dzięki tej funkcjonalności użytkownik może przeanalizować:

- sposób propagacji wybranych cech w populacji,
- tempo rozprzestrzeniania się określonych schematów,
- wpływ operatorów genetycznych na zachowanie wzorców genotypowych,
- stabilność i trwałość wybranych struktur w kolejnych pokoleniach.

Możliwość dynamicznego włączania i wyłączania filtra schematów pozwala na interaktywne badanie działania algorytmu genetycznego oraz lepsze zrozumienie teorii schematów w praktycznym zastosowaniu.

3. Wykorzystane technologie